Olympe Dotsu & Imane Guarraz
Bachelor 3 IA & DATA

Analyse de Données Avancée

RAPPORT - 18 avril 2026

ADVANCED MARKETING ANALYTICS BUSINESS INTELLIGENCE & DECISION INTELLIGENCE

Pour accéder à l'intégralité du projet (Notebook, README, etc)

Lien Github :
https://github.com/ImaneGuarraz/projet_analyse_donnees_avancee_Bachelor3_IA-DATA

imane.guarraz@ynov.com

olympe.dotsu@ynov.com

Sommaire

INTRODUCTION : problématique, dataset, environnement de travail

PARTIE 1 : Data Audit & Data Quality

PARTIE 2 : Analyse multidimensionnelle et compréhension métier

PARTIE 3 : Segmentation clients

PARTIE 4 : KPI métier et lecture décisionnelle

PARTIE 5 : Dashboard décisionnel

PARTIE 6 : Analyse prédictive et scoring métier

CONCLUSION

Comment transformer un dataset marketing en un système décisionnel capable d'éclairer la segmentation, le ciblage, la performance campagne et la feuille de route analytique de l'entreprise ?

Le Dataset

Le dataset utilisé provient de Kaggle et regroupe environ **2240 clients**, chacun décrit par un ensemble de 29 variables couvrant des **dimensions socio-démographiques, comportementales et marketing.** On y retrouve notamment des informations relatives à l'âge, au revenu, au niveau d'éducation, à la situation familiale, ainsi qu'aux comportements d'achat à travers différentes catégories de produits.

En complément, le dataset inclut des variables liées à l'historique des campagnes marketing, permettant d'observer les réactions des clients face aux sollicitations passées. La variable cible, intitulée "Response", indique si un client a répondu à la dernière campagne, ce qui en fait un élément central pour l'analyse et la modélisation prédictive.

Le choix des outils

L'organisation du projet :

GitHub s'est imposé comme un choix naturel pour ce projet car il offre un cadre structuré, professionnel et collaboratif pour gérer du code. Il permet de versionner chaque étape du développement, de conserver un historique clair des modifications et de revenir à une version antérieure en cas d'erreur. GitHub facilite également la sauvegarde sécurisée du projet dans le cloud, ce qui évite toute perte de données et permet de travailler depuis plusieurs machines. Enfin, c'est un outil standard dans le monde professionnel de la data et du développement, ce qui renforce la rigueur et la crédibilité du projet.

Lien Github : https://github.com/ImaneGuarraz/projet_analyse_donnees_avancee_Bachelor3_IA-DATA

La production Python

Nous avons choisi d'utiliser à la fois VSCode et Jupyter Notebook car ces deux outils sont complémentaires dans un projet de data science. Jupyter nous a permis de réaliser toute la phase exploratoire : tester rapidement du code, analyser les données, visualiser les résultats et documenter chaque étape de manière interactive. VSCode, de son côté, nous a servi pour structurer le projet, écrire des scripts propres, gérer plusieurs fichiers, utiliser un terminal intégré et préparer le dashboard Streamlit dans un environnement plus robuste.

En combinant les deux, nous avons pu profiter de la flexibilité de Jupyter pour l'analyse et de la puissance de VSCode pour l'industrialisation du code, ce qui a rendu le workflow plus efficace et professionnel.

Synthèse des étapes

PARTIE 1 : Data Audit & Data Quality

Une première étape essentielle a consisté à réaliser un audit approfondi de la qualité des données. Cette phase a permis d'identifier plusieurs éléments susceptibles d'impacter les analyses. Des valeurs manquantes ont été observées, notamment sur la variable de revenu, ce qui a nécessité une stratégie d'imputation afin de préserver la cohérence globale du dataset sans introduire de biais significatif. Notre base de données comprend 2 240 observations, ce qui reste relativement limité. Il est donc important d'effectuer un nettoyage rigoureux tout en minimisant la perte d'informations.

Dans un premier temps, nous supprimons les lignes contenant des valeurs manquantes, celles-ci représentant moins de 5 % de la base. Par ailleurs, aucune duplication ni valeur négative incohérente n'a été détectée. Ensuite, nous procédons à l'identification des valeurs aberrantes pour l'ensemble des variables quantitatives. Pour cela, nous utilisons d'abord des visualisations de type boxplots afin d'obtenir une première indication. Nous calculons ensuite les écarts-types ainsi que les seuils inférieurs et supérieurs, en appliquant la méthode de Tukey. Les valeurs situées en dehors de ces seuils sont considérées comme aberrantes. Lorsqu'elles représentent moins de 5 % des données, elles sont supprimées ; sinon, elles sont remplacées par la médiane.

Concernant les variables qualitatives, nous vérifions dans un premier temps que toutes les valeurs présentes appartiennent bien à leurs catégories respectives. Nous procédons ensuite à un retraitement des modalités afin d'améliorer la cohérence et la lisibilité. Par exemple, certaines catégories du statut marital ont été regroupées : les modalités "absurd" et "yolo" ont été fusionnées dans une catégorie "other", tandis que "alone" a été renommée en "single". Nous avons également transformé la variable date de naissance en une nouvelle variable âge, permettant une lecture plus directe et l'identification d'éventuelles valeurs aberrantes (par exemple, des âges supérieurs à 100 ans). Dans le même principe, nous avons fait évolué la variable "Dt_Customer", vers une variable en année, via un calcul à date du jour, pour avoir une variable décrivant l'ancienneté des clients en années.

Enfin, dans un objectif de simplification de lecture du dataset, nous avons cherché à regrouper des données de manière pertinente, sans perdre en information. Les champs concernant la composition du foyer, les dépenses, les achats ou l'historique de réponse aux précédentes campagnes, avaient à la base plusieurs variables. Nous avons donc évalué la pertinence de regrouper certaines variables en vérifiant 3 points :

- les variables d'un même groupe racontent la même histoire
- aucune variable individuelle n'a un pouvoir prédictif fort qui serait dilué dans l'agrégation
- la variable composite améliore ou maintient la relation avec Response

Nous avons mesurer l'importance individuelle de chaque variable par rapport à la cible (Response) grâce à l'AUC et à la Mutual Information. Ensuite, nous avons réalisé une analyse de la cohérence interne du groupe via les corrélations et une PCA pour voir si un composite peut résumer les variables. Enfin, nous avons comparé trois modèles (variables séparées, composite seul, mix) pour vérifier si le regroupement améliore ou dégrade la performance prédictive. Cette approche permet de décider objectivement quels groupes doivent être fusionnés, conservés séparément ou simplifiés.

Nous avons utilisé la même méthode pour la variables “Income”, qui nous semblait intéressant de segmentée. Finalement, les résultats ont démontré qu’en segmentant “Income”, en regroupant les variables d’achats ou celles de la composition du foyer, nous allions perdre des informations crutiales. Nous avons donc regroupé en feature, uniquement les variables de dépenses et d’historique de réponse aux précédentes campagnes.

À ce stade du traitement de données, nous avons pu passer à la suite du projet, l’analyse de données avancées.

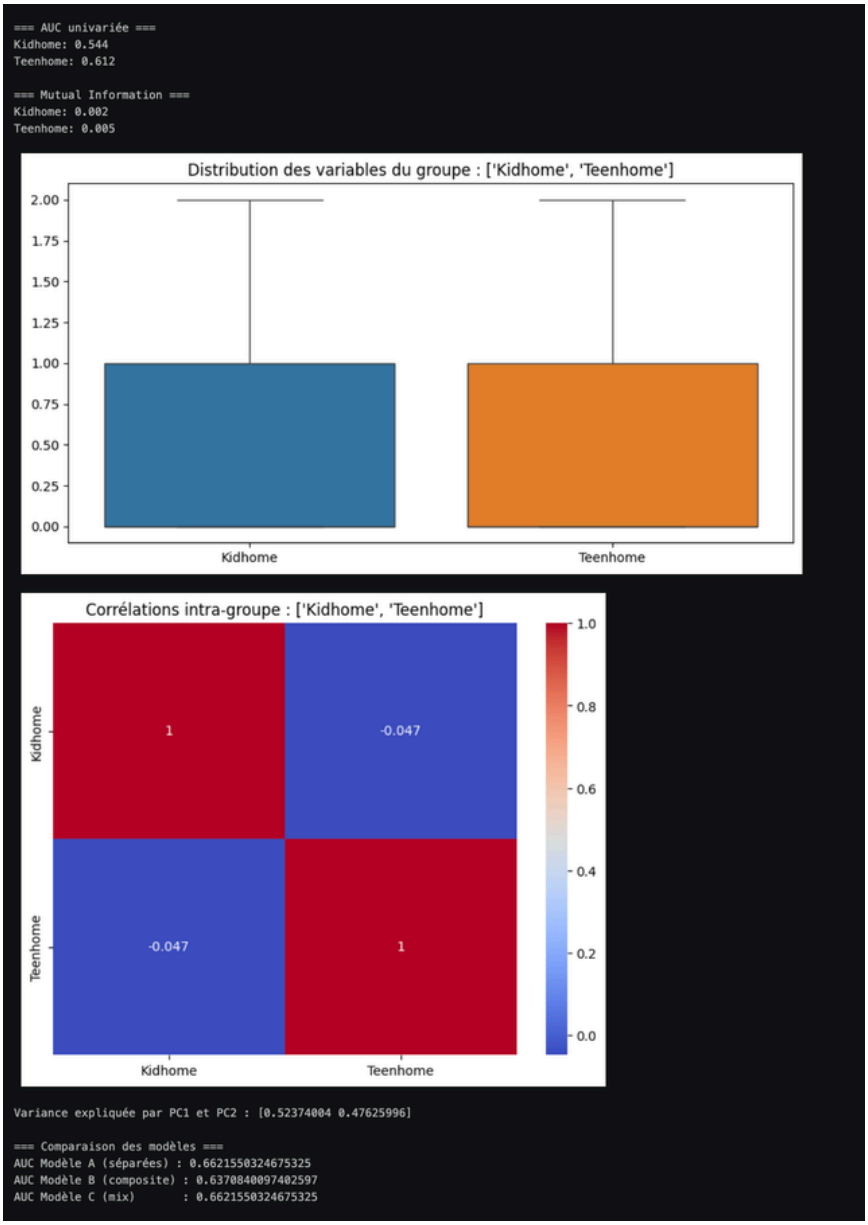

Exemple d’analyse de pertinence d’un potentiel regroupement de variable entre Kidhome et Teenhome.

PARTIE 2 : Analyse multidimensionnelle et compréhension métier

L'étude a débuté par une exploration détaillée des variables disponibles. Le portefeuille présente un profil relativement mature, avec un âge moyen d'environ 52 ans et une ancienneté moyenne de 12,7 ans. Le revenu annuel moyen s'élève à environ 54 000 €, mais avec une dispersion importante, révélant la coexistence de clients à fort pouvoir d'achat et d'autres plus modestes. Les dépenses totales suivent une distribution très asymétrique : une majorité de clients dépensent peu, tandis qu'une minorité concentre une part importante de la valeur.

L'analyse exploratoire a permis de visualiser les distributions des différentes variables parmi notre population observée. Par exemple, nous avons constaté une omniprésence de Married, de Graduation et de Response = 0.

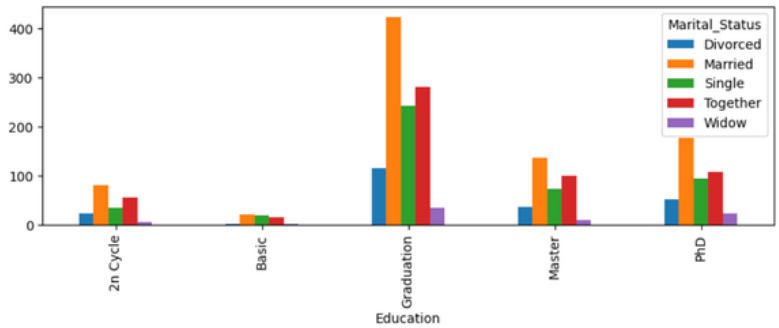

Exemple d'analyse bivariée à l'aide d'un diagramme de répartition entre les groupes Education et Marital_Status.

L'analyse des comportements d'achat montre que les achats en magasin restent dominants, mais les achats web et catalogue constituent des signaux importants d'engagement. Les visites web mensuelles révèlent également des différences marquées entre clients très actifs et clients peu connectés. Enfin, le taux de réponse global aux campagnes marketing atteint 14,4 %, ce qui constitue un niveau correct mais laisse entrevoir un potentiel d'optimisation.

Les analyses bivariées ont mis en évidence plusieurs relations structurantes. Les clients à revenu élevé dépensent davantage, ce qui confirme l'existence d'un lien entre pouvoir d'achat et valeur générée. Les clients les plus actifs sur les canaux digitaux sont également ceux qui dépensent le plus, ce qui suggère que l'engagement digital constitue un levier important. Enfin, les clients ayant déjà répondu à des campagnes présentent un niveau de dépense supérieur, ce qui valide l'intérêt de cibler les segments réactifs.

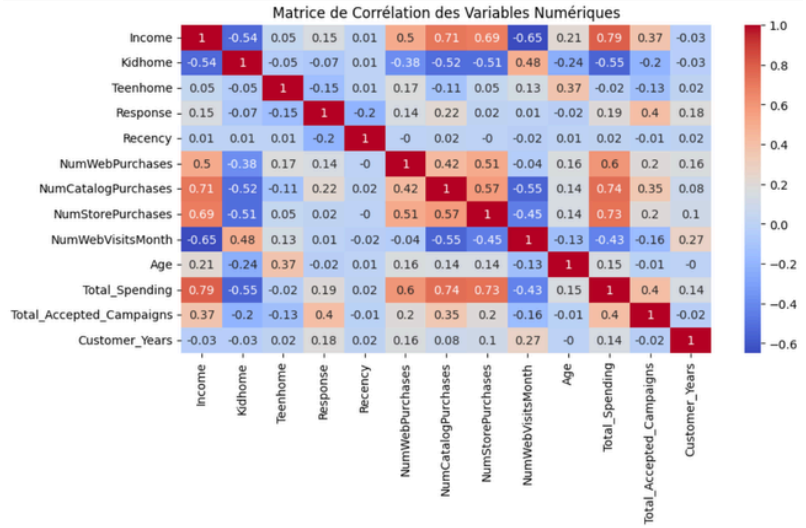

Exemple d'analyse bivariée à l'aide de la matrice de corrélation.

PARTIE 3 : Segmentation clients

Afin d'identifier des groupes homogènes, une segmentation statistique a été réalisée à l'aide de l'algorithme K-Means. Plusieurs valeurs de k ont été testées. La méthode du coude (Elbow) a montré une nette diminution de l'inertie jusqu'à k=4, puis une stabilisation.

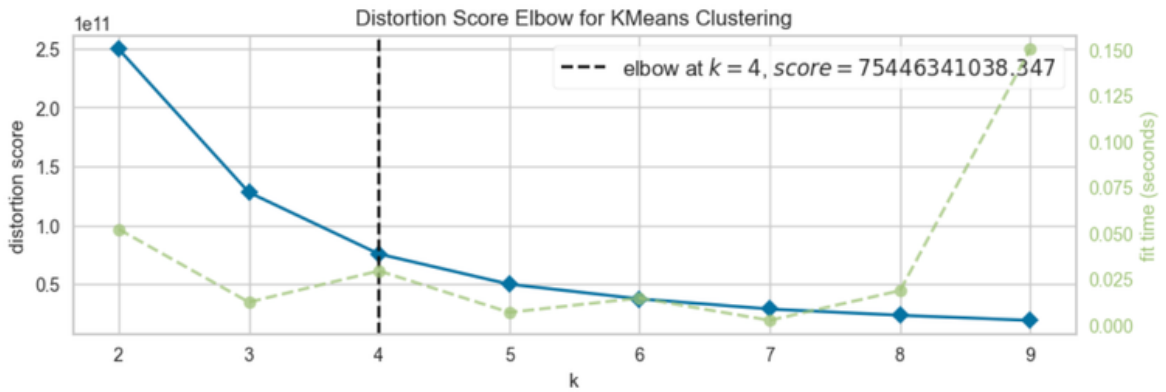

Test de Elbow pour définir le nombre de cluster dans notre segmentation.

Le score de silhouette a confirmé que quatre clusters représentaient un compromis optimal entre cohérence statistique et lisibilité métier.

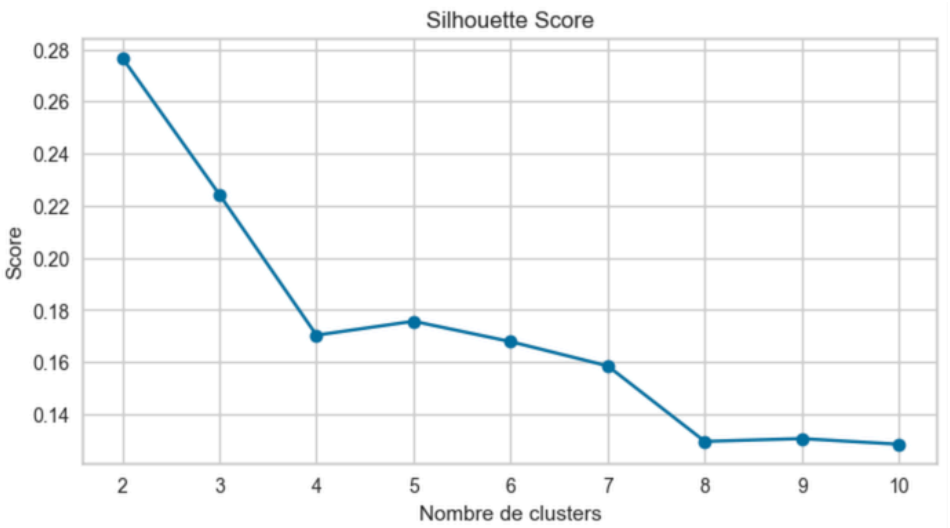

Résultat du test avec le score de Silhouette.

La segmentation finale met en évidence quatre groupes de clients aux profils nettement différenciés.

Le **premier segment** regroupe les clients les plus rentables. Ils disposent d'un revenu moyen de plus de 76 000 €, dépensent en moyenne 948 €, et affichent un taux de réponse exceptionnel de 28,3 %. Leur score de valeur composite atteint 48,6, ce qui en fait le segment prioritaire pour les actions marketing. Ils constituent le cœur de cible, à fidéliser et à valoriser.

Le **deuxième segment** se distingue par une forte activité digitale et un niveau de dépense élevé (763 € en moyenne). Leur revenu est également supérieur à la moyenne. Leur taux de réponse est plus modéré, mais leur potentiel est important. Leur score de valeur de 40,1 les positionne comme un segment stratégique à développer, notamment via des campagnes digitales ciblées.

Le **troisième segment** est composé de clients plus âgés, à revenu moyen et à faible dépense (128 €). Leur taux de réponse est très faible (7,1 %), ce qui limite l'intérêt de campagnes intensives. Leur score de valeur de 20,5 confirme qu'ils doivent être traités avec parcimonie, via des actions de fidélisation douce.

Enfin, le **quatrième segment** regroupe des clients plus jeunes ou à revenu modeste. Leur dépense moyenne est faible (109 €), mais leur activité web est correcte. Leur taux de réponse est légèrement supérieur à celui du segment 3, mais leur score de valeur reste bas (19,0). Ils représentent un potentiel à long terme, mais une faible valeur immédiate.

Cette segmentation offre une lecture claire du portefeuille : deux segments concentrent la valeur (1 et 2), tandis que les deux autres nécessitent des stratégies adaptées mais moins coûteuses.

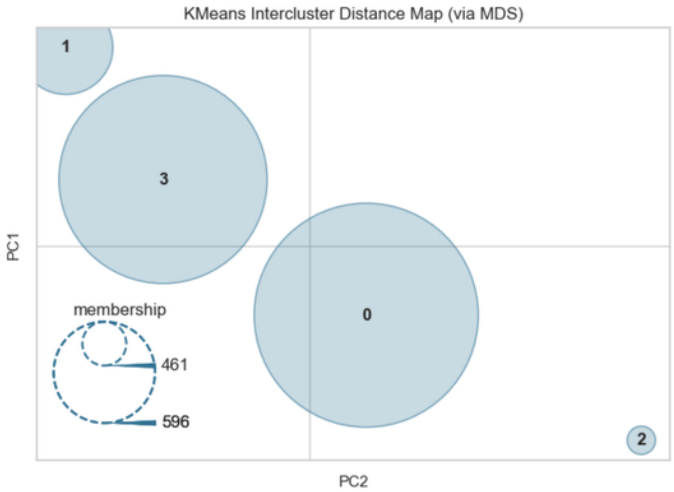

Test de distance entre les clusters.

PARTIE 4 : KPI métier et lecture décisionnelle

Dans une optique de pilotage, plusieurs indicateurs clés ont été définis afin de traduire les analyses en éléments directement exploitables par les décideurs.

À partir de cette segmentation, plusieurs indicateurs clés ont été construits afin de permettre aux équipes marketing de piloter efficacement leurs actions.

Le taux de réponse global de 14,4 % masque des disparités importantes entre segments. Le segment 1, avec 28,3 %, est deux fois plus réactif que la moyenne, ce qui en fait une cible privilégiée. Les segments 0 et 2 présentent des niveaux intermédiaires, tandis que le segment 3 est nettement moins sensible aux campagnes.

Les indicateurs de valeur client confirment la hiérarchie observée. Le revenu moyen varie de 29 899 € pour le segment 0 à 76 366 € pour le segment 1. Les dépenses suivent la même logique, avec un écart de 109 € à 948 €. Ces différences justifient pleinement une stratégie différenciée.

Un score de valeur composite a été construit pour synthétiser la valeur actuelle, le potentiel et l'engagement. Il combine les dépenses, le revenu, la réponse aux campagnes et l'activité digitale. Les résultats confirment la supériorité des segments 1 et 2, qui concentrent l'essentiel du potentiel marketing.

Les KPI clés pour les équipes marketing incluent le taux de réponse global et par segment, le revenu et la dépense moyenne, ainsi qu'un score de valeur client combinant pouvoir d'achat, engagement et activité digitale. Ces indicateurs permettent d'identifier les segments premium, de prioriser les investissements marketing et de piloter l'évolution de la valeur client au fil des mois.

PARTIE 5 : Dashboard décisionnel

Pour rendre l'analyse exploitable par les équipes marketing, un tableau de bord interactif a été développé sous Streamlit. Il permet une lecture rapide et intuitive des principaux indicateurs.

La **première vue** offre une synthèse du portefeuille : nombre total de clients, dépense moyenne, taux de réponse global, score de valeur moyen et répartition des segments. Cette vue permet de comprendre immédiatement la structure du portefeuille.

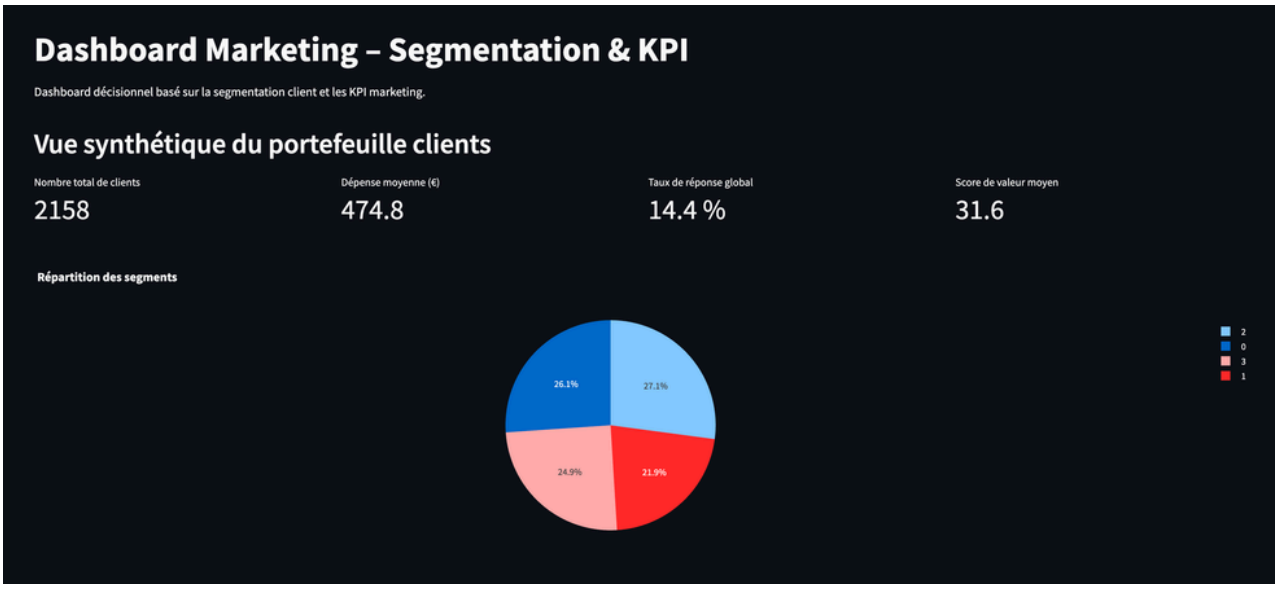

La **seconde vue** est consacrée à la segmentation. Elle présente les profils moyens par segment, une heatmap des variables clés et un tableau comparatif. Cette vue permet d'explorer les différences comportementales et socio-démographiques entre segments.

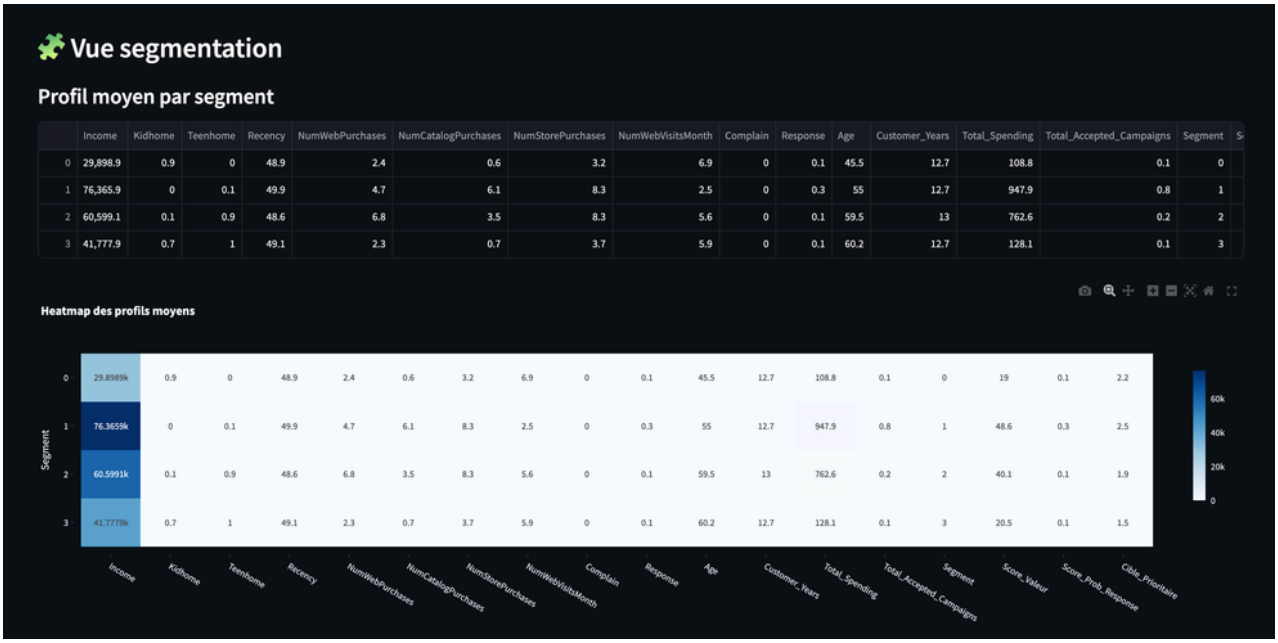

	Income	Kidhome	Teenhome	Recency	NumWebPurchases	NumCatalogPurchases	NumStorePurchases	NumWebVisitsMonth	Complain	Response	Age	Customer_Years	Total_Spending	Total_Accepted_Campaigns	Segment
0	29,898.9	0.9	0	48.9	2.4	0.6	3.2	6.9	0	0.1	45.5	12.7	108.8	0.1	0
1	76,365.9	0	0.1	49.9	4.7	6.1	8.3	2.5	0	0.3	55	12.7	947.9	0.8	1
2	60,599.1	0.1	0.9	48.6	6.8	3.5	8.3	5.6	0	0.1	59.5	13	762.6	0.2	2
3	41,777.9	0.7	1	49.1	2.3	0.7	3.7	5.9	0	0.1	60.2	12.7	128.1	0.1	3

Segment	Income	Kidhome	Teenhome	Recency	NumWebPurchases	NumCatalogPurchases	NumStorePurchases	NumWebVisitsMonth	Complain	Response	Age	Customer_Years	Total_Spending	Total_Accepted_Campaigns	Segment	Score_Valeur	Score_Prob_Response	Cible_Prioritaire
0	29.8989k	0.9	0	48.9	2.4	0.6	3.2	6.9	0	0.1	45.5	12.7	108.8	0.1	0	19	0.1	2.2
1	76.3659k	0	0.1	49.9	4.7	6.1	8.3	2.5	0	0.3	55	12.7	947.9	0.8	1	48.6	0.3	2.5
2	60.5991k	0.1	0.9	48.6	6.8	3.5	8.3	5.6	0	0.1	59.5	13	762.6	0.2	2	40.1	0.1	1.9
3	41.7779k	0.7	1	49.1	2.3	0.7	3.7	5.9	0	0.1	60.2	12.7	128.1	0.1	3	20.5	0.1	1.5

La **troisième vue** analyse la performance marketing. Elle met en évidence le taux de réponse par segment, le nombre moyen de campagnes acceptées et les comportements d'achat. Elle permet d'identifier les segments les plus réactifs et les plus rentables.

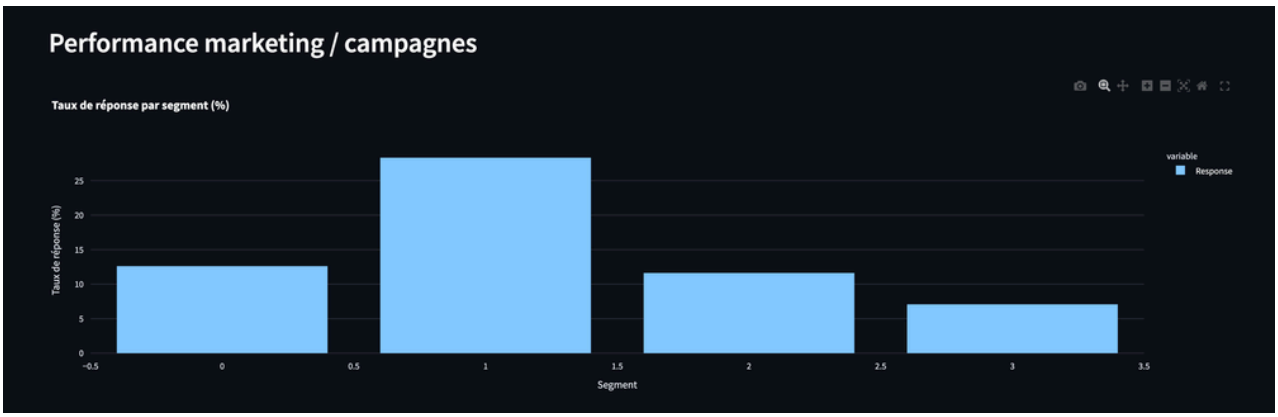

Nombre moyen de campagnes acceptées par segment

Segment	Total_Accepted_Campaigns
0	0.1
1	0.77
2	0.22
3	0.08

La **quatrième vue** regroupe les KPI exécutifs : revenu moyen, dépense moyenne, score de valeur et contribution des segments. Cette vue est destinée aux décideurs souhaitant piloter la stratégie globale.

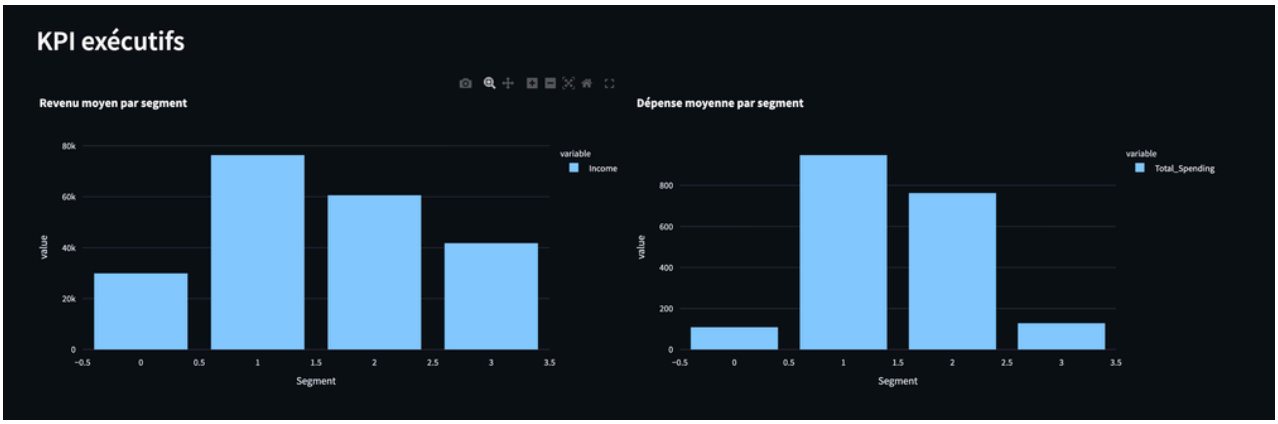

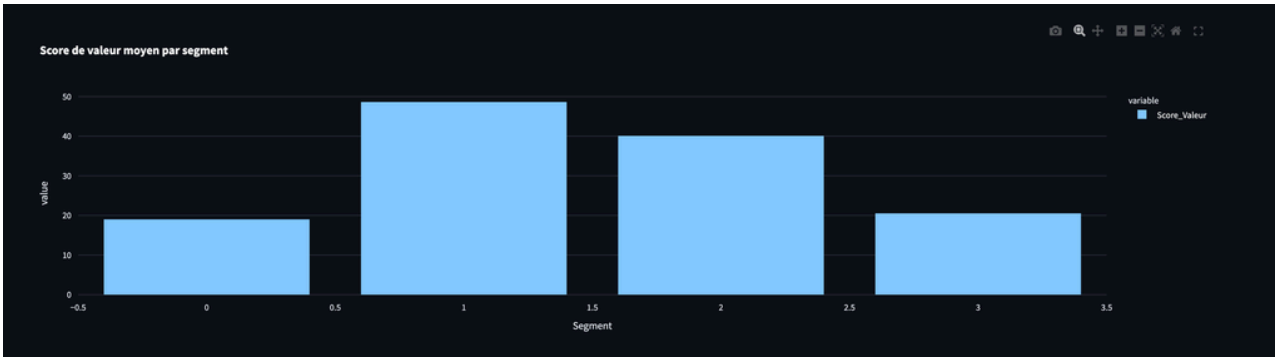

Enfin, une dernière section propose des recommandations opérationnelles pour chaque segment. Les clients premium doivent bénéficier d'offres exclusives et de programmes de fidélisation renforcés. Les clients digitaux à potentiel doivent être ciblés via des campagnes web personnalisées. Les segments à faible valeur doivent être traités avec des actions légères et peu coûteuses.

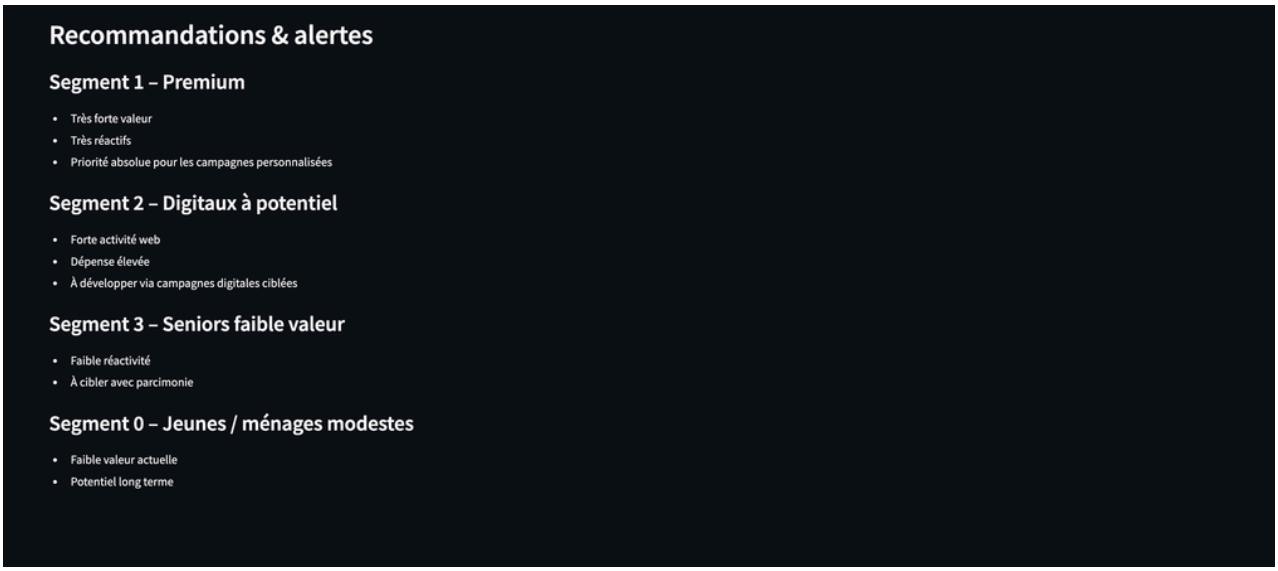

PARTIE 6 : Analyse prédictive et scoring métier

Dans cette dernière partie, nous avons intégré une brique de modélisation prédictive afin d'estimer la probabilité qu'un client réponde à une campagne marketing. L'objectif était double : d'une part, mesurer la capacité du modèle à discriminer les répondants des non-répondants, et d'autre part, construire un score de propension permettant de prioriser les actions marketing. La variable cible retenue est Response, qui indique si un client a répondu positivement à une campagne précédente. Ce choix est cohérent avec un usage métier orienté vers l'optimisation du ciblage.

Pour construire ce modèle, nous avons sélectionné un ensemble de variables explicatives représentatives du comportement client : le revenu, la composition du foyer, la récence d'achat, les différents types d'achats (web, catalogue, magasin), les visites web mensuelles, l'âge, l'ancienneté, les dépenses totales et le nombre de campagnes acceptées. Ces variables couvrent à la fois des dimensions socio-démographiques, transactionnelles et comportementales, ce qui permet au modèle de capturer des signaux variés liés à la propension à répondre.

Le modèle retenu est **une régression logistique,** principalement pour sa simplicité, sa robustesse et son interprétabilité. Dans un contexte marketing, il est essentiel de pouvoir expliquer les résultats à des équipes non techniques et de disposer d'un score de probabilité directement exploitable. La régression logistique répond parfaitement à ces exigences, tout en offrant des performances très compétitives sur des données de ce type. Les variables ont été standardisées afin d'assurer une convergence optimale du modèle et une meilleure comparabilité des coefficients.

Le modèle a été entraîné sur un échantillon d'apprentissage représentant 75 % des données, tandis que les 25 % restants ont servi à l'évaluation. Les performances ont été mesurées à l'aide de l'AUC (Area Under the ROC Curve), une métrique particulièrement adaptée dans un contexte de ciblage. L'AUC mesure la capacité du modèle à classer correctement les répondants avant les non-répondants, indépendamment du seuil de décision.

Le modèle atteint une AUC de 0.852, ce qui constitue une performance très élevée pour un modèle marketing. Concrètement, cela signifie que dans 85,2 % des cas, le modèle attribue une probabilité plus élevée à un client qui répond qu'à un client qui ne répond pas.

La courbe ROC associée montre une montée rapide vers le coin supérieur gauche, confirmant la forte capacité discriminante du modèle.

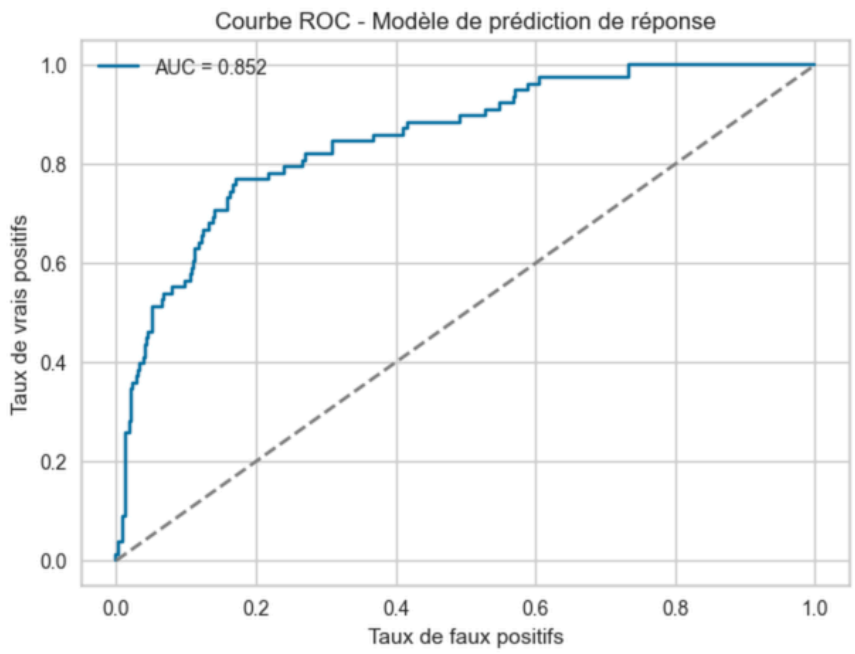

Courbe ROC pour confirmer la capacité discriminante du modèle.

Au-delà de l'évaluation globale, nous avons examiné la distribution des probabilités prédites. Celle-ci montre une séparation nette entre les clients à forte probabilité et ceux à faible probabilité, ce qui est essentiel pour un usage opérationnel. Les scores prédits ont ensuite été intégrés dans le dataframe sous la forme d'une nouvelle variable, **Score_Prob_Response**, qui représente la probabilité individuelle de réponse pour chaque client. Les valeurs observées illustrent bien la capacité du modèle à différencier les profils : certains clients obtiennent des scores supérieurs à 0.75, indiquant une forte propension à répondre, tandis que d'autres se situent autour de 0.02 ou 0.01, traduisant une probabilité extrêmement faible.

	Score_Prob_Response	Cible_Prioritaire
0	0.782061	4
1	0.032111	1
2	0.071796	2
3	0.037157	1
4	0.011147	0

Afin de rendre ce score exploitable par les équipes marketing, nous avons construit un indicateur de priorisation basé sur un découpage en quintiles. La **variable Cible_Prioritaire** prend ainsi une valeur de 0 à 4, où 4 correspond aux 20 % de clients ayant la probabilité la plus élevée de répondre.

Par exemple, un client avec un score de 0.782 est classé dans la catégorie 4, ce qui en fait une cible prioritaire pour les campagnes. À l'inverse, un client avec un score de 0.011 est classé dans la catégorie 0, indiquant qu'il ne doit pas être ciblé dans des campagnes coûteuses.

Ce mécanisme de priorisation permet de transformer un modèle statistique en un outil opérationnel directement utilisable pour optimiser les budgets marketing.

En conclusion, cette brique de modélisation prédictive apporte une dimension supplémentaire à l'analyse : elle permet non seulement de comprendre les comportements passés, mais aussi d'anticiper les comportements futurs. Avec une AUC de 0.852 et une capacité claire à prioriser les clients, le modèle constitue un outil fiable, interprétable et immédiatement exploitable pour optimiser les campagnes marketing et renforcer la performance globale de la stratégie client.

Conclusion

Ce projet démontre qu'un dataset marketing peut être transformé en un véritable outil de pilotage stratégique, à condition de structurer les données, de mener des analyses pertinentes et de les traduire en recommandations opérationnelles. L'approche adoptée, combinant analyse exploratoire, segmentation et modélisation, permet d'apporter une vision complète et cohérente du comportement client.

Au-delà des résultats techniques, la valeur ajoutée du projet réside dans sa capacité à produire des insights directement exploitables par les décideurs. Cette démarche illustre pleinement le rôle de la data dans les organisations modernes, où elle constitue un levier essentiel de performance et de compétitivité.

L'analyse menée permet de dresser un portrait précis et exploitable du portefeuille clients. La segmentation en quatre groupes offre une lecture claire des comportements et de la valeur générée. Les segments 1 et 2 concentrent l'essentiel du potentiel marketing et doivent être priorisés dans les campagnes. Les segments 0 et 3 nécessitent des stratégies adaptées, centrées sur la fidélisation ou l'accompagnement.

Le tableau de bord développé constitue un outil opérationnel permettant aux équipes marketing de suivre les indicateurs clés, d'explorer les segments et de prendre des décisions éclairées. Il transforme l'analyse statistique en un véritable levier de pilotage stratégique.